





군집화(Clustering)

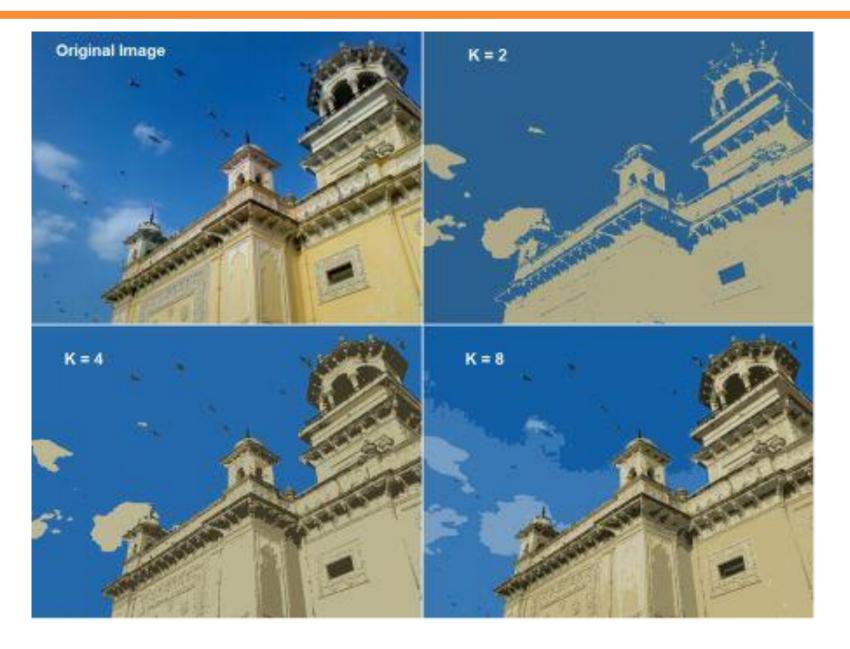
- 지식(정보)가 없는 상태에서 유사(similar)한 데이터를 모아 같은 그룹으로 묶는 일
 - 군집간 분산 최대화, 군집 내 분산 최소화
 - 유사도(similarity) 계산
- 레이블이 없는 대표적인 비지도학습(unsupervised learning)
 - 분류(classification): 지도학습(supervised learning)
- Hierarchical Clustering 과 Partitional Clustering 가 있다.














인공지능(튜링테스트에서 딥러닝까지), 생능출판사

k-평균 알고리즘(k-means algorithm)

입력 : 훈련집합 $X = \{x_1, x_2, \dots, x_n\}$, 군집의 개수 k

출력 : 군집집합 $C = \{c_1, c_2, \cdots, c_k\}$

[pseudo code]


1: k개의 점들을 초기 중심점(centroid)으로 선택한다.


2: repeat


3: 각 점을 가장 가까운 중심점(centroid)에 할당하여 k개의 군집을 형성한다.


4: 각 군집의 중심점을 다시 계산한다.


5: until 중심점이 바뀌지 않을 때까지













No change. Done!





Evaluating Clusters


- 목적함수(objective function)
 - 점들 사이 또는 점과 군집 중심점 간의 인접성에 의존
 - 클러스터의 품질은 오차 제곱의 합(ESS: Error Sum of Squares)으로 평가

$$ESS = \sum_{i=1}^{k} \sum_{x \in c_i} dist(c_i, x)^2$$


$$i$$
번째 군집의 중심점(평균)은
$$c_i = \frac{1}{m_i} \sum_{x \in c_i} x$$


• SSE의 최소화하는 k값을 선택하는 것이 중요

- k가 너무 작으면 별개의 클러스터를 합치고 k가 너무 크면 하나의 클러스터가 여러 개로 나뉜다
- 이너셔(inertia) : 각 샘플과 가장 가까운 센트로이드사이의 평균제곱거리



- 실루엣 계수 = $(b-a)/\max(a,b)$
 - -a: 동일한 클러스터에 있는 다른 샘플까지 평균거리(클러스터 내부의 평균 거리)
 - b: 가장 가까운 클러스터까지 평균거리(가장 가까운 클러스터의 샘플까지 평균 거리)
 - +1에 가까우면 자신의 클러스터안에 잘 속해 있고 다른 클러스터와는 멀리 떨어져 있다는 뜻.
 - 0에 가까우면 클러스터 경계에 위치한다는 의미
 - -1에 가까우면 잘못된 클러스터라는 의미
- 실루엣 점수 : 실루엣 계수의 평균





Ref: hands on machine learning 2nd, or illy

https://stanford.edu/class/engr108/visualizations/kmeans/kmeans.html

